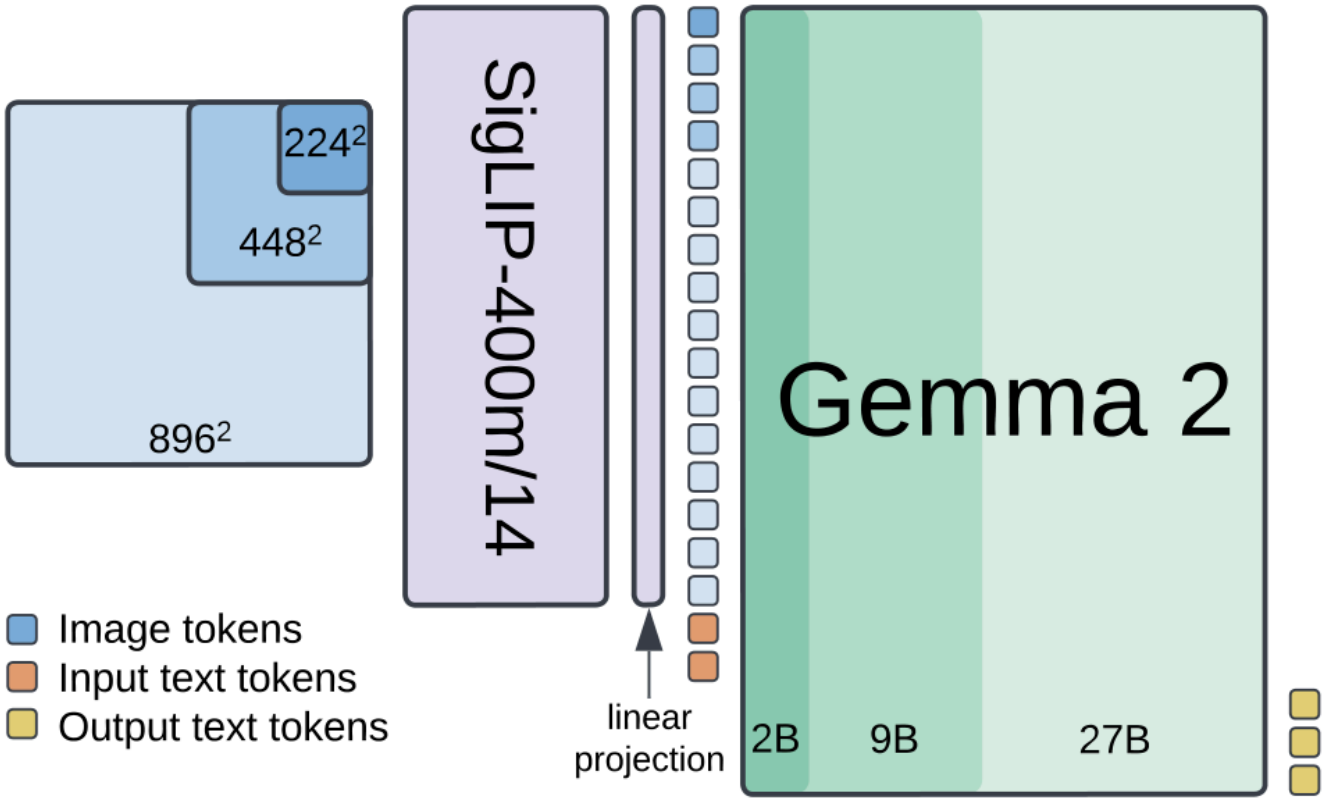
Her Şey Metin: PaliGemma 2 Nasıl Çalışıyor, Neyi Gösteriyor, Neyi Göstermiyor?



PaliGemma 2 mimarisi: SigLIP görüntü kodlayıcı, linear projection ve üç boyutta Gemma 2. Resim çözünürlüğü 224, 448 veya 896 piksel. Kaynak: PaliGemma 2 (Steiner vd., 2024), Figure 1. CC BY 4.0.

Bir görsel-dil modelini (VLM) daha iyi hale getirmek istediğinizi düşünün. Önünüzde iki seçenek var. Birincisi modele daha yüksek çözünürlüklü resimler vermek, yani daha keskin bir **göz**. İkincisi arkadaki dil modelini büyütmek, yani daha büyük bir **beyin**. İkisi de pahalı. Hangisine yatırım yapmalısınız?

Google DeepMind'ın Aralık 2024'te yayımladığı **PaliGemma 2: A Family of Versatile VLMs for Transfer** makalesi bu soruyu kontrollü bir deneyle cevaplamaya çalışıyor. Bu yazıda önce modelin nasıl çalıştığını, sonra

makalenin cevabını anlatacağım. Ardından modeli ücretsiz Colab'da kendim çalıştırıp Türkçe tabelalar ve fişler üzerinde yaptığım küçük deneyi paylaşacağım. Son olarak makalenin beni ikna etmeyen yerlerine bakacağım.

PaliGemma 2 ne, neyi soruyor?

PaliGemma, Google'ın 2024'te çıkardığı 3 milyar parametreli, açık ağırlıklı bir görsel-dil modeliydi. PaliGemma 2 aynı mimariyi koruyor ama dil modelini **Gemma 2**'ye yükseltiyor. Bu kez tek bir model değil, bir **aile** var: 3 boyut (3B, 10B, 28B) × 3 çözünürlük (224, 448, 896 piksel). Başlıktaki "for Transfer" ifadesi de önemli. Bu modeller kutudan çıktığı gibi sohbet etmek için değil, sizin göreviniz için **fine-tune edilmek** için tasarlanmış.

Makalenin bence asıl katkısı **kontrollü bir karşılaştırma**. Model boyutunun etkisine bakan çalışmalar genellikle farklı laboratuvarların farklı tariflerle eğittiği modelleri karşılaştırıyordu, yani elmayla armudu. Burada 9 modelin hepsi aynı görüntü kodlayıcıyı, aynı dil modeli ailesini ve aynı eğitim tarifini kullanıyor. Böylece "çözünürlük mü, model boyutu mu?" sorusu temiz bir şekilde sorulabiliyor. Üstüne model OCR, tablo, molekül, nota ve röntgen raporu gibi daha önce denenmemiş alanlara uygulanıyor.

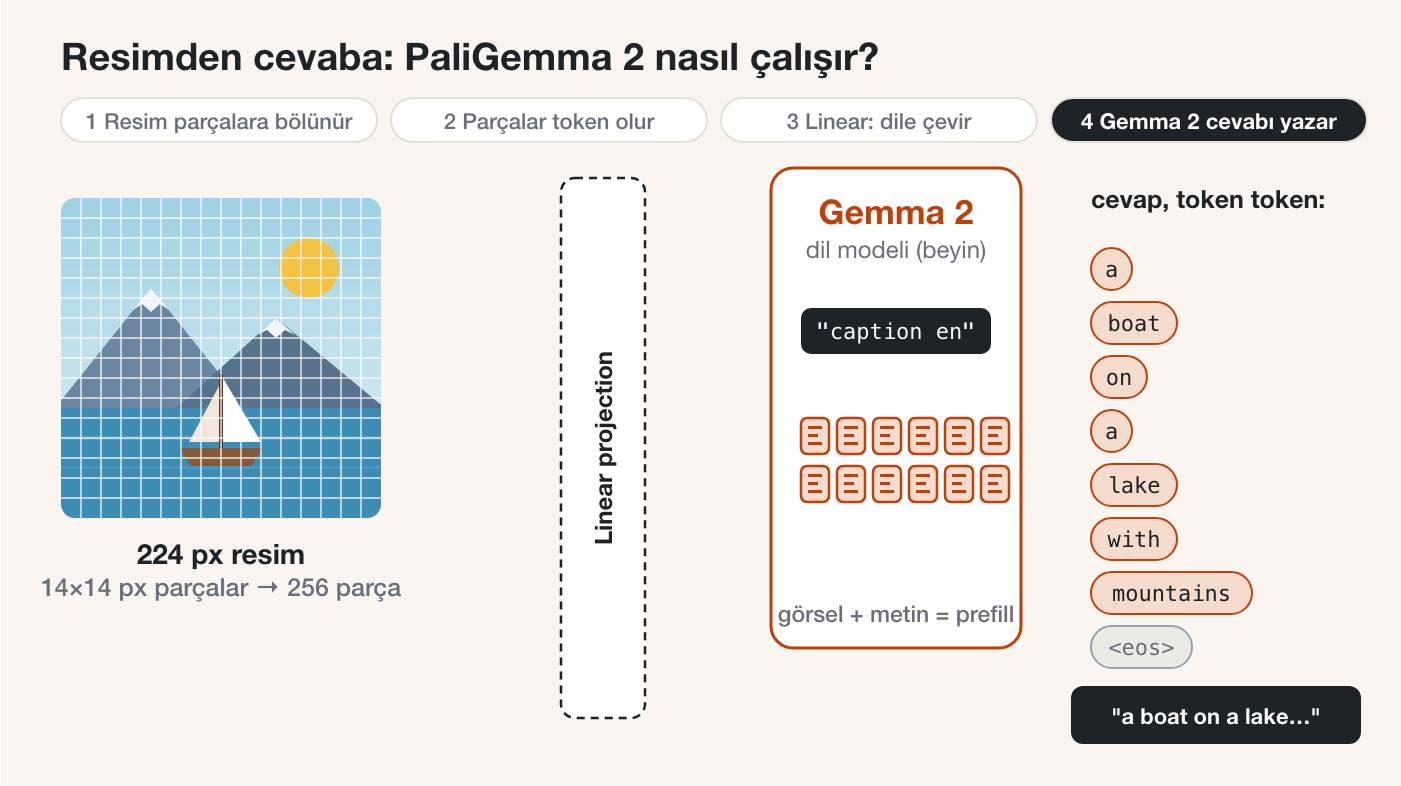
Resimden cevaba: model nasıl çalışıyor?

Mimari şaşırtıcı derecede sade ve PaliGemma 1 ile birebir aynı. Üç parçası var:

- **SigLIP-So400m:** Görüntü kodlayıcı, yani modelin gözü. Yaklaşık 400 milyon parametre.
- **Linear projection:** Görüntü dünyası ile dil dünyası arasındaki köprü. Tek bir doğrusal katman.
- **Gemma 2:** Dil modeli, yani modelin beyni. 2B, 9B ya da 27B.

Model büyütülürken sadece beyin büyüyor. Göz 3B'de de 28B'de de aynı. Bir resim modele girip cevap olarak çıkana kadar şu adımlardan geçiyor:

1. **Resim parçalara bölünür.** SigLIP resmi 14×14 piksellik karelere ayırır ve her kare bir **görsel token** olur. 224 piksellik resim 256, 448 piksellik resim 1.024, 896 piksellik resim **4.096 token** eder.
2. **Tokenlar dile çevrilir.** Linear katman görsel tokenları Gemma'nın anlayacağı boyuta dönüştürür. Artık Gemma'nın gözünde bir resim parçası ile bir kelime aynı türden bir şey.
3. **Görsel ve metin yan yana konur.** Görsel tokenlar ile sizin yazdığınız komut (ör. "caption en") art arda dizilip Gemma'ya verilir.
4. **Cevap kelime kelime yazılır.** Gemma, tıpkı bir sohbet modeli gibi cevabı token token üretir.



Resimden cevaba: resim 14×14 parçalara bölünüyor, her parça bir token oluyor, Gemma 2 cevabı token token yazıyor. Animasyon: yazar.

Bu tasarımın en zarif tarafı şu: **Çıktı her zaman metin.** Peki bir dil modeli bir nesnenin resimdeki yerini nasıl gösterir? Makaledeki örnekte modele iki

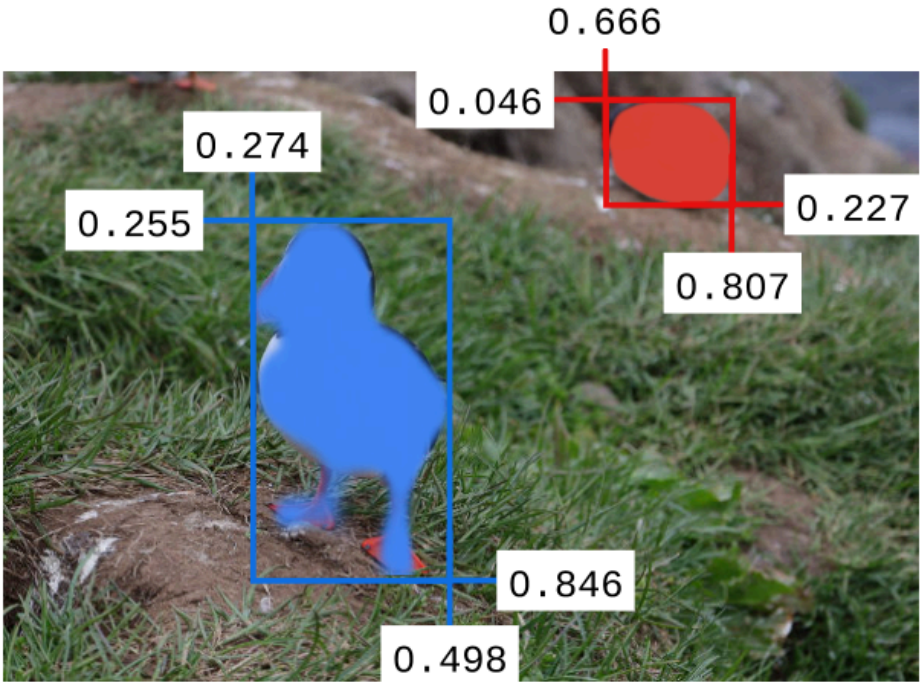
puffin kuşunun olduğu bir fotoğraf ve *"segment puffin in front"* (öndeki puffin'i ayır) komutu veriliyor. Model şöyle bir cevap yazıyor:

```
<loc0255><loc0274><loc0846><loc0498> <seg024> ... <seg018> puffin in front
```

İlk dört token kuşun etrafındaki kutunun köşe koordinatları. Resim her yönde 1.024 dilime bölünüyor ve `<loc0255>` "255. dilim" demek. Ardından gelen `<seg...>` tokenları maskenin şeklini tarif ediyor. Yani model kutu çizmiyor, piksel boyamıyor. Kutuyu ve maskeyi **yazıyor**. Yeni görevlerde de aynı fikir sürüyor: Tablo **HTML**, molekül çizimi **SMILES** dizisi, nota kağıdı ****kern** metni, röntgen de **rapor metni** olarak yazılıyor. Görev değişiyor, mimari hiç değişmiyor.

Input:

```
segment puffin in the back ; puffin in front
```



Output:

```
<loc0255><loc0274><loc0846><loc0498>
<seg024>[...]<seg018> puffin in front ;
<loc0046><loc0666><loc0227><loc0807>
<seg106>[...]<seg055> puffin in the back
```

Makalenin kendi örneği: "arkadaki ve öndeki puffin'i ayır" komutuna modelin cevabı. Kutular <loc>, maskeler <seg> tokenlarıyla metin olarak yazılıyor. Kaynak: PaliGemma 2 (Steiner vd., 2024), Figure 2. CC BY 4.0.

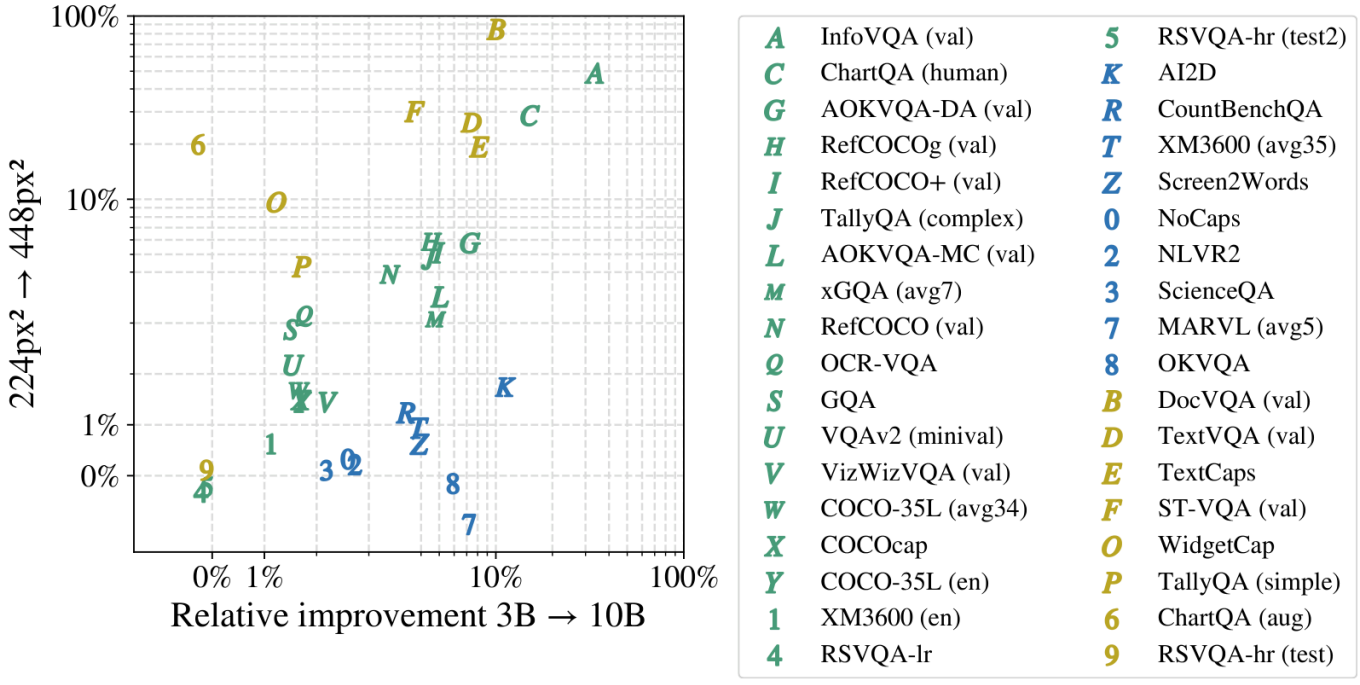
Bir maliyet notu da var. Çözünürlüğü iki katına çıkarmak token sayısını **dört katına** çıkarıyor ve bu tokenların hepsi beynin içinden geçmek zorunda. Makalenin hesabına göre 3B modeli 896 pikselde eğitmek (23.5 birim), 28B modeli 224 pikselde eğitmekten (18.9 birim) daha pahalı. Yani keskin bir göz, dokuz kat büyük bir beyinden pahalıya gelebiliyor.

Asıl soru: göz mü, beyin mi?

Makalenin kalbi 4.1. bölümdeki deney. 3B, 10B ve 28B modellerin her biri 224 ve 448 pikselde, 30'dan fazla benchmark için fine-tune ediliyor. Her ayar 5 kez çalıştırılıp medyanı raporlanıyor. Sonra 3B@224'ten başlanıp iki yöne gidiliyor: ya beyin büyütülüyor (3B → 10B, maliyet yaklaşık 3.7 kat) ya da göz keskinleştiriliyor (224 → 448, maliyet yaklaşık 4.6 kat).

Çoğu görev iki yönden de kazanıyor, ama kazançların dağılımı çok öğretici:

- **Göz isteyen görevler:** Metin, doküman, grafik ve ekran görüntüsü soruları (DocVQA, ChartQA, TextVQA gibi). 224 piksele küçültülmüş bir faturadaki yazıyı okuyamayan bir modele daha büyük bir beyin vermek pek işe yaramıyor. Önce görmesi gerekiyor.
- **Beyin isteyen görevler:** Çok dilli açıklama (XM3600, 35 dil) ve akıl yürütme gerektiren görevler (bilimsel diyagram soruları, nesne sayma, iki resmi karşılaştırma). Burada resmi daha keskin görmek değil, gördüğünü yorumlamak önemli.



Makalenin kalbi: Yatay eksen 3B→10B (beyin), dikey eksen 224→448 px (göz) ile gelen göreceli iyileşme. Sarı: çözünürlükten, mavi: model boyutundan, yeşil: ikisinden de kazanan görevler. Kaynak: PaliGemma 2 (Steiner vd., 2024), Figure 3. CC BY 4.0.

İki yan bulgu daha var. Birincisi, **3B'den 10B'ye geçiş belirgin bir kazanç getiriyor, ama 10B'den 28B'ye geçiş neredeyse hiç getirmiyor.** Oysa 28B'nin maliyeti 10B'nin yaklaşık beş katı. Yazarlar bunu Gemma 2'nin küçük modellerinin daha büyük bir modelden damıtılarak eğitilmesine bağlıyor, ama bu hipotezi test etmiyor. İkincisi pratik bir tavsiye: Model büyüdükçe fine-tuning için en iyi learning rate küçülüyor.

Yeni alanlarda da aynı ayrım ortaya çıkıyor. **OCR, tablo ve nota** gibi ince görsel detay isteyen görevlerde en iyi ayar **3B@896**. **Molekül, uzun açıklama ve uzamsal akıl yürütme** gibi yorum isteyen görevlerde ise **10B** öne çıkıyor. Model bu alanların çoğunda, o iş için özel tasarlanmış modelleri geçiyor. Örneğin nota okumada önceki en iyi modelin hatalarını yarıdan fazla azaltıyor. Röntgen raporu yazmada da tıbba özel Med-Gemini'yi geçiyor.

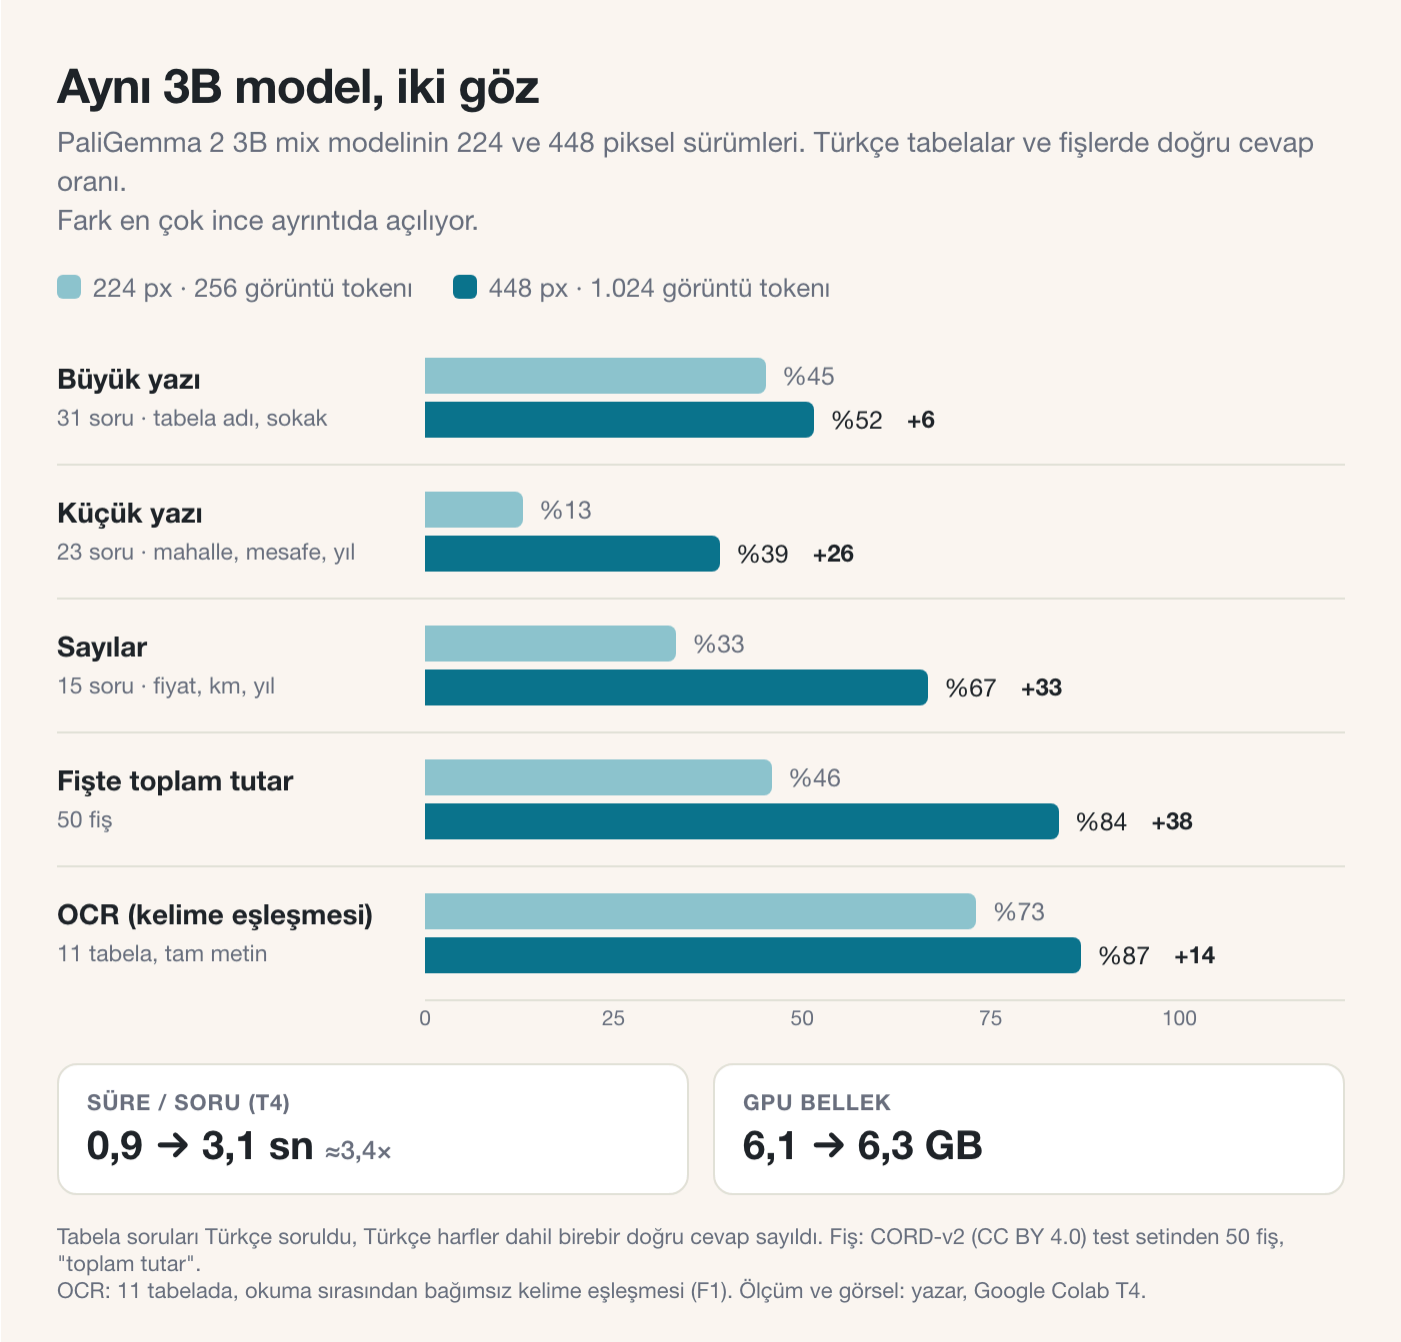
Ben de denedim: Türkçe tabelalar, fişler, iki çözünürlük

Makaleyi okurken en çok "söylüyorlar ama göstermiyorlar" diye şikâyet ettim (aşağıda geleceğim). Ama model açık ağırlıklı, yani bir kısmını kendim test edebilirim. Ücretsiz Google Colab'ın T4 GPU'sunda 3B modelin iki sürümünü çalıştırdım: **mix-224** ve **mix-448**. İkisinin beyni aynı, sadece gözü farklı. "Mix" sürümler birçok görevin karışımıyla fine-tune edilmiş, kutudan çıktığı gibi kullanılabilen modeller. Bu yüzden rakamlarım makaledekilerle birebir kıyaslanamaz. Benim baktığım şey **yön**.

Ne denedim? Wikimedia Commons'tan Türkiye'de çekilmiş, açık lisanslı **41 fotoğraf** topladım: sokak levhaları, uyarı tabelaları, balık tezgâhındaki el yazısı fiyatlar, Galata Kulesi'ndeki kitabe. Bunlar için **54 soru** yazıp doğru cevapları kendim belirledim. Her soruyu hem Türkçe hem İngilizce sordum. Yazının fotoğrafta büyük mü küçük mü olduğunu da ayrıca işaretledim.

Bunlara ek olarak 11 tabelada tam metin okuma (`ocr`) ve CORD veri setinden **50 fişte** toplam tutarı sordum.

Göz farkı ince ayrıntıda açılıyor



224 ve 448 pikselde aynı 3B model. Ölçüm ve görsel: yazar.

Büyük tabela yazılarında iki model birbirine yakın (%45'e karşı %52). Mahalle adı, mesafe ya da kanun numarası gibi küçük yazılarda ise 224 neredeyse hiç okuyamıyor (%13), 448 üç kat daha iyi (%39). En net sonuç fişlerde: Toplam

tutarı 224 fişlerin %46'sında, 448 ise %84'ünde doğru buldu. Bu, makalenin "metin okuyan görevler göz ister" bulgusunun, makalenin hiç bakmadığı bir veride, Türkçe sokak tabelalarında da geçerli olduğunu gösteriyor. Bedeli de var: Soru başına süre 0,9 saniyeden 3,1 saniyeye çıkıyor.

Okuyamayınca uyduruyor

Beni en çok şaşırtan, yüzdeler değil yanlışların türü oldu. 224 bir yazıyı okuyamadığında "bilmiyorum" demiyor, akıcı ve inandırıcı bir şey uyduruyor.

Okuyamayınca uyduruyor

Galata Kulesi'ndeki kitabe, iki modele de aynı komutla verildi: `ocr`.
224 "okuyamıyorum" demiyor, akıcı ama yanlış bir metin yazıyor.



Fotoğraf: Wikimedia Commons, "GalataKulesiTabelası.jpg", kamu malı.

KİTABEDE YAZAN

29 MAYIS 1453 SALI SABAHI CENEVİZLERİN GALATA KOLONİSİ ANAHTARLARINI FATİH SULTAN MEHMED'E TAKDİM ETMİŞ VE GALATANIN TESLİMİ 1 HAZİRAN CUMA GÜNÜ TAMAMLANMIŞDIR. İSTANBUL FETHİ DERNEĞİ 1953

224 PX — **KELİME F1 %45**

20 MAYIS **1938** **SALİH** **SABAHİ** CENEVİZLERİN **ÇALIŞMA** KOLONİSİ **AMFIYASI** **FAİD** SULTAN MEHMEDE TAKDİM ETMİŞ VE GALATANIN TESLİMİ I HAZİRAN CUMA GÜNÜ TAMAM **LANMİSİR.** **ÇANKAYA** **BELEDİYE**

448 PX — **KELİME F1 %81**

29 MAYIS 1453 SALI SABAHI CENEVİZLERİN GALATA KOLONİSİ ANAHTARIARINI FATİH SULTAN MEHMEDE TAKDIM ETMİŞ VE GALATANIN TESLİMİ 1 HAZİRAN CUMA GÜNÜ TAMAM LANMIŞDIR. İSTANBUL FETHİ DERNEĞİ, 1953

kelime yanlış / uydurma kelime tek harf hatası

Model: PaliGemma 2 3B mix (224 ve 448). Satır sonları tek satıra birleştirildi. Ölçüm ve görsel: yazar.

Galata Kulesi kitabesi, iki modelin `ocr` çıktısı. Fotoğraf: Wikimedia Commons, kamu malı. Görsel: yazar.

Kitabedeki "29 Mayıs 1453 Salı sabahı" ifadesi 224'te **"20 Mayıs 1938 Salih sabahi"** olmuş. "Aydın Büyükşehir Belediyesi" yazan levhayı "Kızılay Belediyesi" diye okudu. Sigara tabelasına olmayan bir cümle ekledi: "Sigara içenler uyarıdan ötekileşirler." 448 aynı kitabeyi iki harf hatasıyla okudu, ama o da kusursuz değil: Bir levhada aynı satırları tekrar tekrar yazdı. Göz yetersiz kaldığında model boşluğu dil bilgisiyle dolduruyor. Bu bence yüzdelerden daha önemli bir uyarı, çünkü yanlış cevap da doğru cevap kadar emin görünüyor.

Türkçe: soruyu Türkçe sorun, harflere güvenmeyin

Beklemediğim bir sonuç: **Türkçe sorular İngilizcelerden daha iyi sonuç verdi** (448'de %46'ya karşı %37). İngilizce sorunca model cevabı çeviriyor. "Burada ne yasak?" sorusunu Türkçe sorunca "sigara", İngilizce sorunca "smoking" diyor. 224 alabalık etiketine İngilizce soruda "alabama" bile dedi. İngilizce sorularda daha kolay pes de ediyor ve daha sık "cevaplanamaz" diyor.

Türkçe harflerde ise ilginç bir ayrım var. `ocr` komutunda 448 Türkçe harflerin %94'ünü doğru yazıyor. Ama soruya cevap verirken aynı harfleri düşürüyor: "acil cikis", "cinarcik", "bayat ekmek askisi". Metni doğru bulduğu 14 cevabın sadece 3'ünde harfler de doğru. Yani model harfleri görüyor ama cevap yazarken kullanmıyor. Benim tahminim, soru-cevap eğitim verisindeki cevapların İngilizce harflere indirgenmiş olması. Ama bunu test etmedim.

Türkçe resim açıklamaları da zayıf. Hamsi kovası için Türkçe açıklama istedim, cevap İngilizce ve yanlış geldi: "Invertebrate food is for sale in a red bucket" ("Kırmızı kovada omurgasız yiyecek satılıyor"). Aynı resmin İngilizce açıklaması ise etiketi bile okuyordu: "hamsi 4 mtl". Makale çok dilli açıklamayı "beyin isteyen" görevler arasında sayıyordu. 3B'nin Türkçede bocalaması buna uyuyor. Ama 10B'yi ücretsiz GPU'da çalıştıramadığım için bu bir doğrulama değil, sadece uyumlu bir gözlem.

Sınırlar: 54 soruda her soru yaklaşık 2 puan ediyor, yani tabelalardaki birkaç puanlık farklar kesin değil. Fiş sonucu ise sağlam: 448'in doğru, 224'ün yanlış bildiği 23 fiş var, tersi sadece 2. Soruları ben yazdım ve puanlamam katı. Türkçe harfleri görmezden gelince 448'in başarısı %46'dan %67'ye çıkıyor. Notebook ve veri seti: Colab notebook.

Beni ikna etmeyen noktalar

Göz/beyin ayrımı sağlam: Aynı tarifle eğitilmiş modeller, 30'dan fazla benchmark ve 5 tekrar var. Makalenin en güvenilir bulgusu bu. Ama dört noktada ikna olmadım.

1. Söylüyorlar ama göstermiyorlar. Yeni görevlerin neredeyse hepsinde "çözünürlüğü düşürünce kötüleşti" ya da "modeli büyütmek işe yaramadı" deniyor, ama bunun rakamları verilmiyor. Makalenin ana iddiası tam olarak bu soru hakkında olduğu için bu eksiklik daha da göze batıyor. Yukarıdaki deney, böyle bir karşılaştırmanın ücretsiz bir GPU'da yarım saatte yapılabildiğini gösteriyor.



"Söylendi mi, gösterildi mi?" Yeni görevlerde çözünürlük ve model boyutu karşılaştırmalarının hangilerinin rakamla desteklendiği. Analiz ve görsel: yazar.

2. 28B neredeyse hiç görünmüyor. 4.1'de 10B'den 28B'ye kazanç az çıktı, ama sonuç bölümü "büyük varyantlar ciddi iyileşme getiriyor" diyor. Yeni görevlerin hiçbirinde 28B sonucu yok.

3. Göz/beyin karşılaştırması eşit maliyetli değil. Çözünürlük artışı yaklaşık 4.6 kat, model büyütme 3.7 kat maliyetli. Yani göze %25 daha fazla

bütçe verilmiş. Learning rate de sadece 224 pikselde seçilip 448'e aynen taşınmış. Eşit bütçeli bir "göz mü, beyin mi?" deneyini görmek isterdim.

4. Bazı karşılaştırmalar adil değil, bazıları eksik. Uzun açıklama görevinde PaliGemma 2 bu veri setinde fine-tune edilmişken LLaVA gibi rakipler hiç eğitilmeden test edilmiş. Adil olan tek karşılaştırma PaliGemma 1 ile 2 arasındaki. Röntgen raporları ise sadece otomatik metriklerle ölçülmüş, hiçbir radyolog değerlendirmemiş. Uzun açıklamada insan değerlendirmesi yapılmışken, bunun çok daha kritik olduğu tıbbi görevde yapılmaması ironik. Yeni görevlerde 5 tekrar da bırakılmış, yani küçük farkların şans mı gerçek mi olduğunu bilemiyoruz.

Sonuç

PaliGemma 2 mimari olarak yeni bir şey önermiyor. Ama kontrollü bir model ailesi sunarak pratik bir soruya cevap veriyor: **Modelinize göz mü, beyin mi eklemelisiniz?** İnce görsel detay istiyorsanız çözünürlüğe, yorum istiyorsanız daha büyük bir dil modeline yatırım yapın. Çoğu durumda 10B tatlı nokta gibi görünüyor.

Açık ağırlıklı modeller sayesinde makalenin göstermediği deneylerin bir kısmını topluluk kendisi yapabilir. Ben bunu küçük ölçekte denedim. Türkçe tabelalarda göz farkı makalenin söylediği gibi çıktı. Ama asıl ders başkaydı: Küçük göz, okuyamadığı yerde uyduruyor. Model Türkçe harfleri de görüyor ama cevap yazarken düşürüyor.

Kaynak: Steiner, A., Pinto, A. S., Tschannen, M., et al. (2024). *PaliGemma 2: A Family of Versatile VLMs for Transfer*. arXiv:2412.03555. arxiv.org/abs/2412.03555

İleri okuma:

- Introducing PaliGemma 2 — Google Developers Blog
- Welcome PaliGemma 2 — Hugging Face Blog
- PaliGemma 2 model ağırlıkları — Hugging Face